

Introduzione al Machine Learning


Docente: Tommaso Muraca



Cos'è il Machine Learning

L'**apprendimento automatico** (anche detto machine learning in inglese) è una **branca dell'intelligenza artificiale** che raccoglie metodi che utilizzano **metodi statistici** per migliorare la **performance** di un **algoritmo nell'identificare pattern nei dati**.

Nell'ambito dell'informatica, l'apprendimento automatico è una **variante alla programmazione tradizionale** nella quale in una macchina si predispone **l'abilità di apprendere qualcosa dai dati** in maniera **autonoma**, senza istruzioni esplicite.



Importanza del Machine Learning

L'**intelligenza artificiale plasmerà il nostro futuro** in modo più potente di qualsiasi altra innovazione di questo secolo.

Il **tasso di accelerazione è già sorprendente**, già nel **2015**, **Google** aveva formato un **agente conversazionale (AI)** che non solo poteva **interagire in modo convincente con gli esseri umani** come helpdesk di supporto tecnico, ma anche **discutere** di moralità, esprimere opinioni e rispondere a domande generali basate sui fatti.

Lo stesso anno, **DeepMind** ha sviluppato un **agente** che ha **superato le prestazioni a livello umano in 49 giochi Atari**, ricevendo come input solo i pixel e il punteggio del gioco. Poco dopo, nel **2016**, **DeepMind** ha reso **obsoleti i propri risultati** rilasciando un nuovo metodo di gioco all'avanguardia chiamato **A3C**.

Nel frattempo, **AlphaGo** ha **sconfitto** uno dei migliori **giocatori umani a Go**: un risultato straordinario in un gioco dominato dagli umani per due decenni dopo che le macchine avevano conquistato per la prima volta gli scacchi.

Molti **esperti del gioco** non riuscivano a capire come era **possibile per una macchina cogliere tutte le sfumature** e la complessità di questo antico gioco di strategia di guerra cinese, con le sue 10^{170} possibili posizioni sul tabellone (ci sono solo 10^{80} atomi nell'universo).

Importanza del Machine Learning

Nel **marzo 2017**, **OpenAI** ha creato agenti che hanno inventato il proprio linguaggio per cooperare e raggiungere in modo più efficace il proprio obiettivo. **Poco dopo**, secondo quanto riferito, **Facebook** ha addestrato con successo gli agenti a **negoziare e persino a mentire**.

Poco dopo, l'11 agosto 2017, **OpenAI** ha raggiunto un altro incredibile traguardo **sconfiggendo i migliori professionisti** del mondo in **partite 1v1** del gioco multiplayer online **Dota 2**.

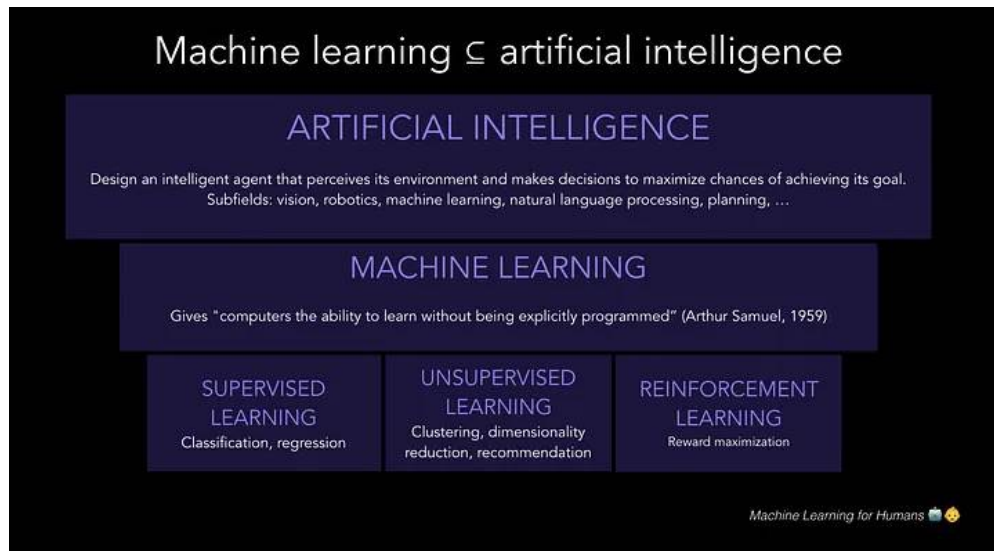
Gran parte della nostra **tecnologia quotidiana** è alimentata **dall'intelligenza artificiale**. Punta la fotocamera sul **menu** durante il tuo prossimo **viaggio a Taiwan** e le selezioni del ristorante appariranno magicamente in italiano tramite **l'app Google Translate**.

Oggi **l'intelligenza artificiale** viene utilizzata per progettare piani di trattamento basati sull'evidenza per i **malati di cancro**, **analizzare istantaneamente** i risultati dei **test medici** per rivolgersi immediatamente allo specialista appropriato e condurre ricerche scientifiche per la scoperta di farmaci.

Intelligenza Artificiale e Machine Learning

L'intelligenza artificiale è lo studio degli agenti che **percepiscono il mondo che li circonda**, formulano piani e prendono decisioni per raggiungere i **propri obiettivi**. I suoi **fondamenti** includono **matematica, logica, filosofia, probabilità, linguistica, neuroscienze e teoria delle decisioni**. Molti campi rientrano sotto l'egida dell'intelligenza artificiale, come la visione artificiale, la robotica, l'apprendimento automatico e l'elaborazione del linguaggio naturale.

Machine Learning è un **sottocampo dell'intelligenza artificiale**. Il suo **obiettivo è consentire ai computer di apprendere da soli**. L'algoritmo di apprendimento automatico consente di identificare modelli nei dati osservati, costruire modelli che spiegano il mondo e prevedere cose senza avere regole e modelli espliciti preprogrammati.



Intelligenza Artificiale e Machine Learning

Cosa può effettivamente essere definito “intelligenza artificiale”?

Lo standard esatto per la tecnologia che si qualifica come “AI” è **un po’ confuso** e le interpretazioni cambiano nel tempo. L’etichetta AI tende a **descrivere macchine che svolgono compiti tradizionalmente di competenza umana**. È interessante notare che, una volta che i computer capiscono come svolgere uno di questi compiti, gli esseri umani hanno la **tendenza a spostare l’asticella**, questo è noto come **Effetto dell’intelligenza artificiale**.

Ad esempio, **quando Deep Blue dell’IBM sconfisse** il campione mondiale di scacchi Garry Kasparov nel 1997, **la gente si lamentava** del fatto che utilizzava metodi di “forza bruta” e che **non si trattava affatto di “vera” intelligenza**. Come ha scritto Pamela McCorduck, “Fa parte della storia del campo dell’intelligenza artificiale che ogni volta che qualcuno capisce come far fare qualcosa a un computer - giocare bene a dama, risolvere problemi semplici ma relativamente informali – si alza un coro di critici che dicono: ‘questo non è pensare’” (McCorduck, 2004).

Forse c’è un argomento inerente a ciò che le persone accettano in modo affidabile come “intelligenza artificiale”:

“L’intelligenza artificiale è tutto ciò che non è stato ancora fatto.” -Douglas Hofstadter

Quindi una **calcolatrice conta come AI?** Forse secondo qualche interpretazione. Che **un’auto a guida autonoma?** Oggi sì. In futuro, forse no. La nuova fantastica **startup di chatbot che automatizza un diagramma di flusso?** Certo, perché no.

Intelligenza Generale Artificiale (AGI)

Le **tecnologie discusse finora** sono esempi di **intelligenza artificiale ristretta (ANI)** , che può svolgere efficacemente un compito ben definito.

Nel frattempo, continuiamo a compiere progressi fondamentali verso **l'intelligenza generale artificiale (AGI)** a livello umano, nota anche come **intelligenza artificiale forte** . La definizione di **AGI** è un'intelligenza artificiale in **grado di eseguire con successo qualsiasi compito intellettuale** che un essere umano può fare , incluso l'apprendimento, la pianificazione e il processo decisionale in condizioni di incertezza, comunicare in linguaggio naturale, fare battute, manipolare le persone, scambiare azioni o programmare.

E quest'ultimo è un grosso problema. Una volta creata un'intelligenza artificiale in grado di migliorarsi, sbloccherà un ciclo di **auto-miglioramento ricorsivo** che potrebbe portare a un'esplosione di intelligenza in un periodo di tempo sconosciuto, che va da molti decenni a un solo giorno.

Questo evento viene chiamato **singolarità** . Il termine è preso in prestito dalla singolarità gravitazionale che si verifica al centro di un buco nero, un punto unidimensionale infinitamente denso dove le leggi della fisica come le comprendiamo iniziano a infrangere.

Nel **2017 il Future of Humanity Institute** ha intervistato un gruppo di ricercatori di intelligenza artificiale sulle tempistiche per l'AGI e ha scoperto che **"i ricercatori ritengono che ci sia una probabilità del 50% che l'intelligenza artificiale superi gli esseri umani in tutti i compiti in 45 anni"**. Leggendo le impressioni dei professionisti dell'intelligenza artificiale ora però ci sono alcuni che prevedono tempi molto più lunghi (il limite superiore è "mai"), e altri le cui tempistiche sono allarmanti: solo pochi anni.

Super Intelligenza Artificiale (ASI)

L'avvento di una **superintelligenza artificiale (ASI)** di **livello superiore a quello umano** potrebbe essere una delle cose migliori o peggiori che possano accadere alla nostra specie. Porta con sé l'immensa sfida di specificare **cosa vorrà l'intelligenza artificiale** in un modo che sia amichevole per gli esseri umani.

Anche se è **impossibile dire cosa riserva il futuro**, una cosa è certa, ormai ogni momento è un buon momento per iniziare a capire come pensano le macchine. Per andare oltre le astrazioni di un filosofo in poltrona e modellare in modo intelligente le nostre tabelle di marcia e le nostre politiche rispetto all'intelligenza artificiale, dobbiamo impegnarci con i dettagli di come le macchine vedono il mondo: cosa "vogliono", i loro potenziali pregiudizi e modalità di fallimento, il loro peculiarità del temperamento, proprio come studiamo la psicologia e le neuroscienze per capire come gli esseri umani apprendono, decidono, agiscono e sentono.

L'apprendimento automatico può essere messo al centro di questo viaggio verso l'intelligenza artificiale generale e, nel frattempo, **cambierà ogni settore e avrà un impatto enorme sulla nostra vita quotidiana.**

Apprendimento Supervisionato

Quanti soldi guadagneremo spendendo più dollari in sponsorizzate? Ha senso concedere un prestito a questa persona? Cosa accadrà domani al mercato azionario?

Nei **problemi di apprendimento supervisionato**, iniziamo con un **set di dati** contenente **esempi di training con etichette corrette** associate . Ad esempio, quando si impara a **classificare le cifre scritte a mano**, un **algoritmo di apprendimento supervisionato** scatta migliaia di immagini di cifre scritte a mano insieme ad etichette contenenti il numero corretto rappresentato da ciascuna immagine. **L'algoritmo apprenderà quindi la relazione tra le immagini e i numeri associati** e applicherà tale relazione appresa per classificare **immagini completamente nuove (senza etichette)** che la macchina non ha mai visto prima. **Ecco come puoi far leggere del testo alla tua fotocamera!**

Per illustrare **come funziona l'apprendimento supervisionato**, esaminiamo il problema di **prevedere il reddito annuo in base al numero di anni di istruzione superiore completati da qualcuno**. In termini più formali, vorremmo costruire un modello che approssimi la relazione f tra il numero di anni di istruzione superiore X e il corrispondente reddito annuo Y .

$$Y = f(X) + \epsilon$$

X (input) = anni di istruzione superiore , **Y (output)** = reddito annuo , **f** = funzione che descrive la relazione tra X e Y ,

ϵ (epsilon) = termine di errore casuale (positivo o negativo) con media nulla. **Epsilon** quindi rappresenta un **errore irriducibile nel modello**, che è un limite teorico alle prestazioni del tuo algoritmo a **causa del rumore intrinseco nei fenomeni che stai cercando di spiegare**. Ad esempio, immagina di costruire un modello per prevedere il risultato del lancio di una moneta.

Apprendimento Supervisionato

Un metodo per prevedere il reddito potrebbe essere quello di creare un modello rigido basato su regole per la relazione tra reddito e istruzione. Ad esempio: "Stimo che per ogni anno in più di istruzione superiore, il reddito annuo aumenta di 5.000 dollari".

$\text{reddito} = (\$ 5.000 * \text{anni_di_istruzione}) + \text{reddito_di_base}$

Questo approccio è un esempio di ingegneria di una soluzione (tra un po' parleremo invece dell'apprendimento di una soluzione, realizzato con il metodo di regressione lineare).

Potremmo elaborare un modello più complesso includendo alcune regole sul tipo di laurea, anni di esperienza lavorativa, livelli scolastici, ecc. Ad esempio: "Se hanno conseguito una laurea o un titolo superiore, fornisci alla stima del reddito un moltiplicatore 1,5x".

Ma questo tipo di programmazione esplicita basata su regole non funziona bene con dati complessi. Immaginiamo di provare a progettare un algoritmo di classificazione delle immagini composto da istruzioni if-then che descrivono le combinazioni di luminosità dei pixel che dovrebbero essere etichettate come "gatto" o "non gatto".

L'apprendimento automatico supervisionato risolve questo problema facendo sì che il computer svolga il lavoro per te. Identificando modelli nei dati, la macchina è in grado di formare proprie soluzioni. La differenza principale tra questo e l'apprendimento umano è che l'apprendimento automatico funziona sull'hardware del computer ed è meglio compreso attraverso la lente dell'informatica e della statistica, mentre il pattern-matching umano avviene in un cervello biologico (pur raggiungendo gli stessi obiettivi).

Nell'apprendimento supervisionato, la macchina tenta di apprendere da zero la relazione tra reddito e istruzione, eseguendo dati di formazione etichettati attraverso un algoritmo di apprendimento. Questa funzione appresa può essere utilizzata per stimare il reddito di persone il cui reddito Y non è noto, a patto di avere come input gli anni di istruzione X . In altre parole, possiamo applicare il nostro modello ai dati di test senza etichetta per stimare Y .

L'obiettivo dell'apprendimento supervisionato è prevedere Y nel modo più accurato possibile quando vengono forniti nuovi esempi in cui X è noto e Y è sconosciuto.

Regressione

I due compiti dell'apprendimento supervisionato sono la **regressione** e la **classificazione**:

Regressione: prevedere un **valore numerico continuo**. A quanto verrà venduta quella casa?

Classificazione: assegnare un'**etichetta**. Questa è la foto di un gatto o di un cane?

Partiamo dalla **regressione** e spieghiamola nel dettaglio, prevede una variabile **target continua Y** e consente di **stimare un valore**, ad esempio i prezzi delle case o la durata della vita umana, **sulla base dei dati di input X**.

La **variabile target** indica la **variabile sconosciuta che ci interessa prevedere** e **continuo** significa che **non ci sono lacune (discontinuità) nel valore che Y può assumere**. Il peso e l'altezza di una persona **sono valori continui**. Le **variabili discrete**, d'altro canto, possono assumere solo un **numero finito di valori**: ad esempio, il numero di figli che qualcuno ha è una variabile discreta.

La **previsione del reddito** è un **classico problema di regressione**. I dati di **input X** includono **tutte le informazioni rilevanti** sugli individui nel set di dati che possono essere utilizzate per prevedere il reddito, come **anni di istruzione**, anni di **esperienza lavorativa**, **titolo professionale** o **codice postale**. Questi attributi sono chiamati **caratteristiche**, che **possono essere numerici** (es. anni di esperienza lavorativa) o **categoriali** (es. titolo professionale o campo di studio).

Avrai bisogno di quante **più osservazioni di addestramento possibili** mettendo in **relazione queste funzionalità con l'output target Y**, in modo che il tuo **modello possa apprendere la relazione f tra X e Y**.

I dati sono suddivisi in un **set di dati di training** e un **set di dati di test**. Il set di **training ha etichette**, quindi il tuo **modello può imparare da questi esempi etichettati**. Il **set di test non ha etichette**, ovvero non conosci ancora il valore che stai cercando di prevedere. È importante che il tuo **modello possa generalizzare a situazioni mai incontrate** prima in modo che possa funzionare bene sui dati di test.

Regressione

Regressione

$Y = f(X) + \epsilon$, dove $X = (x_1, x_2, \dots, x_n)$

Addestramento : la macchina apprende f dai dati di addestramento etichettati

Test: la macchina prevede Y da dati di test senza etichetta

Si noti che **X può essere un tensore con un numero qualsiasi di dimensioni**. Un **tensore 1D** è un vettore (**1 riga, molte colonne**), un **tensore 2D** è una **matrice (molte righe, molte colonne)**, e quindi si possono avere tensori con 3, 4, 5 o più dimensioni (es. un tensore 3D con righe, colonne e profondità).

Nel nostro **banalmente semplice esempio 2D**, ciò **potrebbe assumere la forma di un file .csv** in cui ogni riga contiene il livello di istruzione e il reddito di una persona. **Aggiungendo più colonne con più funzionalità e avremo un modello più complesso, ma forse più accurato.**

Come possiamo costruire modelli che forniscano previsioni accurate e utili nel mondo reale? Lo facciamo utilizzando **algoritmi di apprendimento supervisionato**.

Supervised Learning: Regression

training set	Observation #	Years of Higher Education (X)	Income (Y)
	1	4	\$80,000
	2	5	\$91,500
	3	0	\$42,000
	4	2	\$55,000

	N	6	\$100,000
test set	1	4	???
	2	6	???

Regressione Lineare

Come **primo passo** ci concentreremo sulla **risoluzione del problema della previsione del reddito** con un **algoritmo di regressione lineare**, poiché i **modelli lineari non funzionano bene con le attività di riconoscimento delle immagini** (questo è il dominio del deep learning, che esploreremo più avanti).

Abbiamo il nostro **set di dati X** e i corrispondenti valori target Y. L'**obiettivo** della **regressione dei minimi quadrati ordinari (OLS)** è **apprendere un modello lineare** che possiamo utilizzare per **prevedere un nuovo y dato un x mai visto prima** con il **minor errore possibile**. Vogliamo indovinare quanto reddito guadagna qualcuno in base a quanti anni di istruzione ha ricevuto.

`X_train = [4, 5, 0, 2, ..., 6] # anni di istruzione post-secondaria`

`y_train = [80, 91,5, 42, 55, ..., 100] # redditi annuali corrispondenti, in migliaia di dollari`

La **regressione lineare** è un **metodo parametrico**, il che significa che **fa un'ipotesi sulla forma della funzione** che mette in **relazione X e Y**. Il nostro modello sarà una funzione che prevede \hat{y} dato un x specifico :

$$\hat{y} = \beta_0 + \beta_1 * x + \epsilon$$

β_0 è l'**intercetta y** e β_1 è la **pendenza della nostra retta**, ovvero di **quanto aumenta (o diminuisce) il reddito** con un anno di istruzione in più.

Il nostro **obiettivo** è **apprendere i parametri del modello** (in questo caso, β_0 e β_1) che **riducono al minimo l'errore nelle previsioni del modello**.

Regressione Lineare

Per trovare i parametri migliori:


1. Definire una **funzione di costo**, o **funzione di perdita**, che **misuri quanto siano imprecise le previsioni del nostro modello**.
2. **Trovare i parametri che minimizzano le perdite**, ovvero rendere il nostro **modello quanto più accurato possibile**.

Graficamente, in due dimensioni, ciò si traduce in una **linea di migliore adattamento**. In tre dimensioni disegneremmo un piano e così via con iperpiani di dimensioni superiori.

Matematicamente, osserviamo la **differenza tra ciascun punto dati reale (y) e la previsione del nostro modello (\hat{y}). Elevare al quadrato queste differenze per evitare numeri negativi e penalizzare differenze maggiori, quindi **sommarle e ottenere la media**. Questa è una misura di quanto bene i nostri dati si adattano alla linea.**

$$Cost = \frac{\sum_1^n ((\beta_1 x_i + \beta_0) - y_i)^2}{2 * n}$$

n = numero di osservazioni. **Usare $2*n$** invece di n fa sì che i calcoli funzionino in modo più pulito quando si prende la derivata per ridurre al minimo la perdita, anche se alcuni esperti di statistica dicono che questa è una bestemmia.



Regressione Lineare e discesa del gradiente

Per un **problema semplice** come questo, possiamo **calcolare una soluzione in forma chiusa** utilizzando il calcolo infinitesimale per **trovare i parametri beta ottimali** che minimizzano la nostra funzione di perdita. Ma **man mano che la funzione di costo diventa più complessa, trovare una soluzione in forma chiusa con il calcolo infinitesimale non è più fattibile**. Questa è la **motivazione per un approccio iterativo chiamato discesa del gradiente**, che ci consente di **minimizzare una funzione di perdita complessa**.

L'**obiettivo** della **discesa del gradiente** è **trovare il minimo della funzione di perdita** del nostro modello ottenendone iterativamente un'approssimazione sempre migliore.

Immaginando di camminare attraverso una valle con una benda sugli occhi con l'obiettivo è trovare il fondo della valle. Come lo faresti?

Un **approccio ragionevole** sarebbe quello di **toccare il terreno intorno a noi e muoverci nella direzione in cui il terreno è in pendenza più ripida**. Faremo un passo e ripeteremo lo stesso procedimento continuamente **finché il terreno non sarà piatto**. Allora sapremo di aver raggiunto il **fondo di una valle**, se **spostandoci in qualsiasi direzione** da dove ci troviamo, ci ritroveremo alla stessa altitudine o più in salita.

Tornando alla **matematica**, il **terreno diventa la nostra funzione di perdita** e la **quota del fondovalle è il minimo di tale funzione**.

Se ripensiamo attentamente alla **funzione di perdita** ci rendiamo conto che questa in realtà una **funzione di due variabili: β_0 e β_1** . Tutte le **restanti variabili vengono determinate**, poiché X , Y e n vengono fornite **durante l'addestramento**. Vogliamo provare a **ridurre al minimo questa funzione**.

La **funzione è $f(\beta_0, \beta_1) = z$** . Per **iniziare la discesa del gradiente**, si fa qualche **ipotesi sui parametri β_0 e β_1** che **minimizzano la funzione**.

Successivamente, trovi le **derivate parziali della funzione di perdita rispetto a ciascun parametro beta: $[dz/d\beta_0, dz/d\beta_1]$** . Una derivata parziale indica di quanto la perdita totale aumenta o diminuisce se si aumenta β_0 o β_1 di una quantità molto piccola.

Regressione Lineare e discesa del gradiente

In altre parole, **quanto aumentando la nostra stima del reddito annuo assumendo un livello di istruzione superiore pari a zero (β_0) aumenterebbe la perdita (cioè l'imprecisione) del nostro modello?**

Allo stesso modo, **se aumentiamo la stima di quanto ogni anno di istruzione influisce sul reddito (β_1), quanto ciò aumenta la perdita (z)?**

Se la **derivata parziale dz/β_1** è un **numero negativo**, allora **β_1 è positivo** perché ridurrà la **perdita totale**. Se la **derivata** è un **numero positivo**, **dobbiamo diminuire β_1** . Se è zero, non dobbiamo modificare **β_1** perché significa che abbiamo raggiunto un ottimo punto.

Continuiamo a farlo finché non **raggiungiamo il fondo**, ovvero l'algoritmo converge e la **perdita è stata ridotta al minimo**. Esistono molti trucchi e casi eccezionali che esulano dallo scopo di questo lavoro, ma in generale è così che si trovano i parametri ottimali per il modello parametrico.

Andiamo ora a vedere qualche esempio pratico.